

GOAI 世界人工智能开源大赛

LabOps Guard

可信多智能体实验守护系统

无证据不诊断 · 无审批不执行 · 无验证不闭环

作品简介

● 项目名称

可信多智能体实验守护系统

LabOps Guard

● 问题与场景

指标回退后，修复过程缺少可证明证据。

谁做、改了什么、是否越权？

● 核心解决方案

六角色职责隔离 + 人工审批 + 断网 Runner

AgentTeams 证据闭环

● 创新点与差异化

Executor 无权宣布成功；失败也是正式结果。

独立验证 · 可阻塞 · 可回滚

● 开放 / 复用价值

7 个版本化 Skill、Schema 与 Runner 契约

训练 · 评测 · 数据 · 发布

● 当前进展

AT-004 六角色实跑，三案例证据已固化。

71.875% × 3 → 97.8124976% × 3

指标恢复，不等于修复可信

AI 实验的真正风险，是把不可复核的动作误判成成功。

真实回退

71.875% × 3

checkpoint、数据、metric、seed 均固定
三次复算完全一致，排除随机波动

错误收口

结果变好

可能来自越权改 metric、污染数据或未审批执行；
没有证据链，就不能把提升当成可信修复。

目标用户：模型研发 • 评测平台 • AI Infra • 算法治理

把一次排障，变成可迁移的治理能力

同一闭环可迁移到训练失败、评测漂移、数据质量和发布验证。

传统排障

快但不可证

建议、执行、验收混在一起
证据散落，异常分支常被跳过

LabOps Guard

可复核闭环

角色、状态、审批、回滚和产物都有合同；
执行者与验证者相互独立。

价值：缩短排障路径 • 阻止越权修复 • 沉淀可复用案例记忆

决策面、执行面、证据面彼此制衡


AgentTeams 负责拆解与交接；人工审批控制风险；Runner 只执行已批准的白名单计划。



Auditor 独立通过后, Commander 才能发布 RESOLVED。

核心状态机：任何失败都保留正式状态

状态迁移只接受结构化产物；提示词输出和仪表盘回放都不是执行证据。




ASSIGNED → EVIDENCE_READY → HYPOTHESES_READY → PLAN_READY → APPROVED → EXECUTED → VERIFIED

安全失败
证据 / 能力不足 → BLOCKED
策略越界 → ROLLED_BACK

可信闭环
指标 + 哈希 + 时序 + Trace
全部通过 → RESOLVED

六角色职责隔离，不是六个聊天身份

每个角色都有权限、禁止项、输入输出合同；Executor 不能自证成功。



实际顺序：Commander → Collector → Analyst → Planner → Executor → Auditor

人工审批不计作 Agent
审批事件单独留痕
批准必须早于执行

身份合同
权限 / 禁止项 / Skill / handoff
逐项可核对

每次交接都能追溯到真实事件与产物

handoff 固定记录 task ID、输入、输出、时间、状态和 Matrix 真实 event_id。




AT-004: 6 次角色交接 + 1 次人工审批 + 权威 Trace 7 entries

Matrix: 事件与顺序
MinIO: 共享 Artifact

ZIP: 便携复核
Dashboard: 只读投影

Skill 不是提示词，而是可校验能力合同

每个 Skill 都写明用途、I/O、调用条件、依赖工具、失败处理、安全边界和复用方式。




schema_version • skill_version • lifecycle • structured errors • fail closed

官方必备字段逐项落在 SKILL.md 与 io-schema.json
能力可跨 Agent、跨仓库复用，不绑定 Demo 绝对路径。

7 个 Skill 包覆盖六角色完整闭环

五个任务 Skill 走主流程；Commander 负责打包证据与发布案例记忆




Commander: pack-lab-evidence + publish-case-memory

0.2.0 · references/io-schema.json · agents/openai.yaml ·
CHANGELOG

失败返回结构化错误；不会静默扩权或跳过状态机。

官方字段逐项映射；官方用云 Skill 是推荐项

赛事允许使用官方 Skills，也允许把关键能力沉淀为自研 Skill；评分看合同、复用和协同证据。



SKILL.md + io-schema.json + openai.yaml + version / lifecycle

当前不实现 MCP Server: HTTP Gateway 已具备参数 Schema、权限、错误、审计和降级合同；
后续迁移只增加协议适配，不重写执行链。

Safe Executor 只下计划，Runner 承担执行

Worker 只提交结构化计划；宿主 Gateway 校验后启动一次性、断网、只读输入的 CPU 容器。

职责隔离

Worker



Runner

plan + approval → Gateway allowlist → ephemeral container

labops/pytorch-cpu-runner:0.2.0 • Python 3.11.15 • Torch 2.5.1+cpu

Gateway
固定 task / incident / run
image + command 白名单

只读输入
project / run 挂载只读
仅 output 与 tmp 可写

运行边界
CPU · non-root
network=None

五件套
run_result / metrics
stdout / stderr / manifest

无 API Key • 无 Token • 不在线安装依赖 • 不修改原始工作区

先查能力，再跑实验

宿主先核对固定镜像与计划策略；容器内再核对 Python、Torch、路径、资源 and 单变量变更。

双层能力检查



AT-004 两层检查均 PASS; APPROVED 时间早于 run start

证据互证, Dashboard 只读

Matrix 记录角色事件, MinIO 与证据 ZIP 保存原始产物; 仪表盘重新计算完整性但无权改状态。



不把未来 MCP / OTel / RAG 能力描述为已实现

AT-004: 从提升到可信

固定对象、单变量沙箱修复、人工审批、断网 Runner 与独立复算共同构成完成证明。

三次独立复算

71.88%



97.81%

baseline × 3 · spread 0 candidate × 3 · spread 0

精确值: 71.875% × 3 → 97.8124976% × 3

审批与能力
APPROVED < run start
host 8/8 · runner 10/10

保护边界
6 组文件哈希不变
only 1 sandbox field
changed

受限执行
Runner 0.2.0 · CPU
non-root · network=none

独立审计
27 ZIP entries · 7 Trace
entries
CHAIN_OK / ACCEPTED

Verification Auditor: PASS / RESOLVED

安全失败也是产品能力

保留依赖缺失和策略越界两条正式案例；它们与主演示使用独立 Incident ID 和证据包。

两条保留案例

BLOCKED



**ROLLED
BACK**

AT-002 Worker 缺 torch

metric.py 非法篡改

不得在线安装依赖；回滚后 metric.py SHA-256 与原始值一致

依赖缺失
不在 Worker 安装 torch
正式保持 BLOCKED

策略越界
修改 metric.py
POLICY_VIOLATION

回滚验证
保护哈希 before == after
原工作区未修改

证据隔离
AT-002 / AT-003 / AT-004
Incident ID 独立

失败分支可复盘、可审计，但不会伪造 RESOLVED

初赛材料已冻结；Release 仍服从许可证门禁

公开可复用成果、最终提交材料和未来适配严格分层；未完成能力不写成已实现。

已完成 • 可复用

Apache-2.0 源码 / 7 Skill / Schema / 三案例证据 / case memory / CI / Dashboard

本次定稿

500 字简介 18 页 PPT + PDF Identity / Skill 矩阵 Runner SBOM / License / NOTICE 复核

发布门禁 • 不冒充完成

基础镜像再分发条款 Debian 源码义务 镜像 NOTICE 包 通过前不创建 Tag / Release

贾奇奇 | 个人参赛者

北京交通大学 · 信息与通信工程硕士 | 研究方向：面向视觉的语义通信

研究与成果

V2V / V2I 视觉语义通信
Transformer 语义分割
Cityscapes mIoU 73.76%
Accuracy 93.828%



SCI Q2 论文
Intelligent Cooperative
Perception
Technology for Vehicles and
Experiments
Based on V2V/V2I Semantic
Communication



独立完成
多 Agent 架构与 7 个 Skill
受限 Runner 与证据系统
Demo / 开源治理 / 提交材料
Python · PyTorch · Docker /
AI Infra

坚持：不以未来能力冒充已实现，不以提示词或回放冒充真实执行证据。