

GOAI 2026 世界人工智能开源大赛

LabOps-Guard

可信 Agent 执行与治理基础设施

Trust Infrastructure for Production Agent Systems

Agent 获得真实执行权限后，谁来证明它值得信任？

● 身份

谁在行动？

Identity

● 权限

它获准做什么？

Policy + Approval

● 执行

真实改了什么？

Secure Runner

● 证据

结果能否复核？

Trace + Bundle

● 审计

谁能判定成功？

Independent Auditor

● 边界

失败能否阻断？

BLOCKED / ROLLED_BACK

AI Engineering: 首个验证场景

验证场景不等于项目定义；Trust Contract 与执行治理链可迁移。

验证场景

AI Engineering

事故触发、采证、分析、计划、受控执行与独立验证形成可复核闭环。

架构复用

4 类 Agent

可迁移到 Coding、Data、Research、Deployment Agent；本版本不宣称已全部实现。

首个验证场景 ≠ 项目定义 • 可复用的是 Trust Contract 与执行治理链

把 Agent 行动变成可验证工程事件

Agent Application → Trust Layer → Secure Runtime → Engineering Environment



Control Plane 保持逻辑架构；Dashboard 只读，不生成综合评分。

六 Agent 的价值是职责隔离，不是角色数量

六个 Identity 共享状态与证据；Executor 不能自证成功，Auditor 独占终态裁决。



Commander → Collector → Analyst → Planner → Executor → Auditor

真实 handoff 留痕
Manager / Worker
task + event reference

Separation of Duties
Executor ≠ Auditor
RESOLVED / ROLLED_BACK / BLOCKED

7 个可复用、版本化、可验证的能力契约

Skill 不是 Prompt: Registry 绑定 Owner、I/O、调用条件、失败状态、安全边界与验证方法。



Registry • Version • Owner • I/O Schema • Invocation • Failure • Security • Validation • Reuse

Commander Skills
pack-lab-evidence 0.2.0 • publish-case-memory 0.1.0

Agent、Skill、Tool 三层分离

control-lab-action v0.2.0 · owner=safe-executor · 真实可验证契约




Invocation: Policy passed && scoped approval exists

Failure
capability missing / timeout / policy
mismatch
→ fail closed

Validation + Reuse
manifest + protected hashes
evaluation / data / controlled engineering

Agent 不能直接调用真实工程环境

Plan → Policy → Human Approval → Tool Contract → Gateway → 一次性断网 Runner



无审批或契约不一致 → Runner 不启动 / BLOCKED

Executor 的成功声明不能关闭事故

Auditor 从原始产物独立重算后置条件、保护哈希、审批时序与 Trace。

职责分离

Executor



Auditor

produces artifacts

decides terminal state

只有 verification-auditor 可以产生终态裁决

检查
metric / manifest
approval timing

裁决
PASS / BLOCKED
POLICY_VIOLATION

输入
plan / raw outputs
protected hashes

禁止
编辑产物
复用 claimed score

**Independent Auditor → RESOLVED / ROLLED_BACK /
BLOCKED**

Trace 与 Evidence Bundle 形成可复核链

Matrix 记录事件顺序，Runner 与 MinIO 保存原始产物；Bundle 由 allowlist 封装。



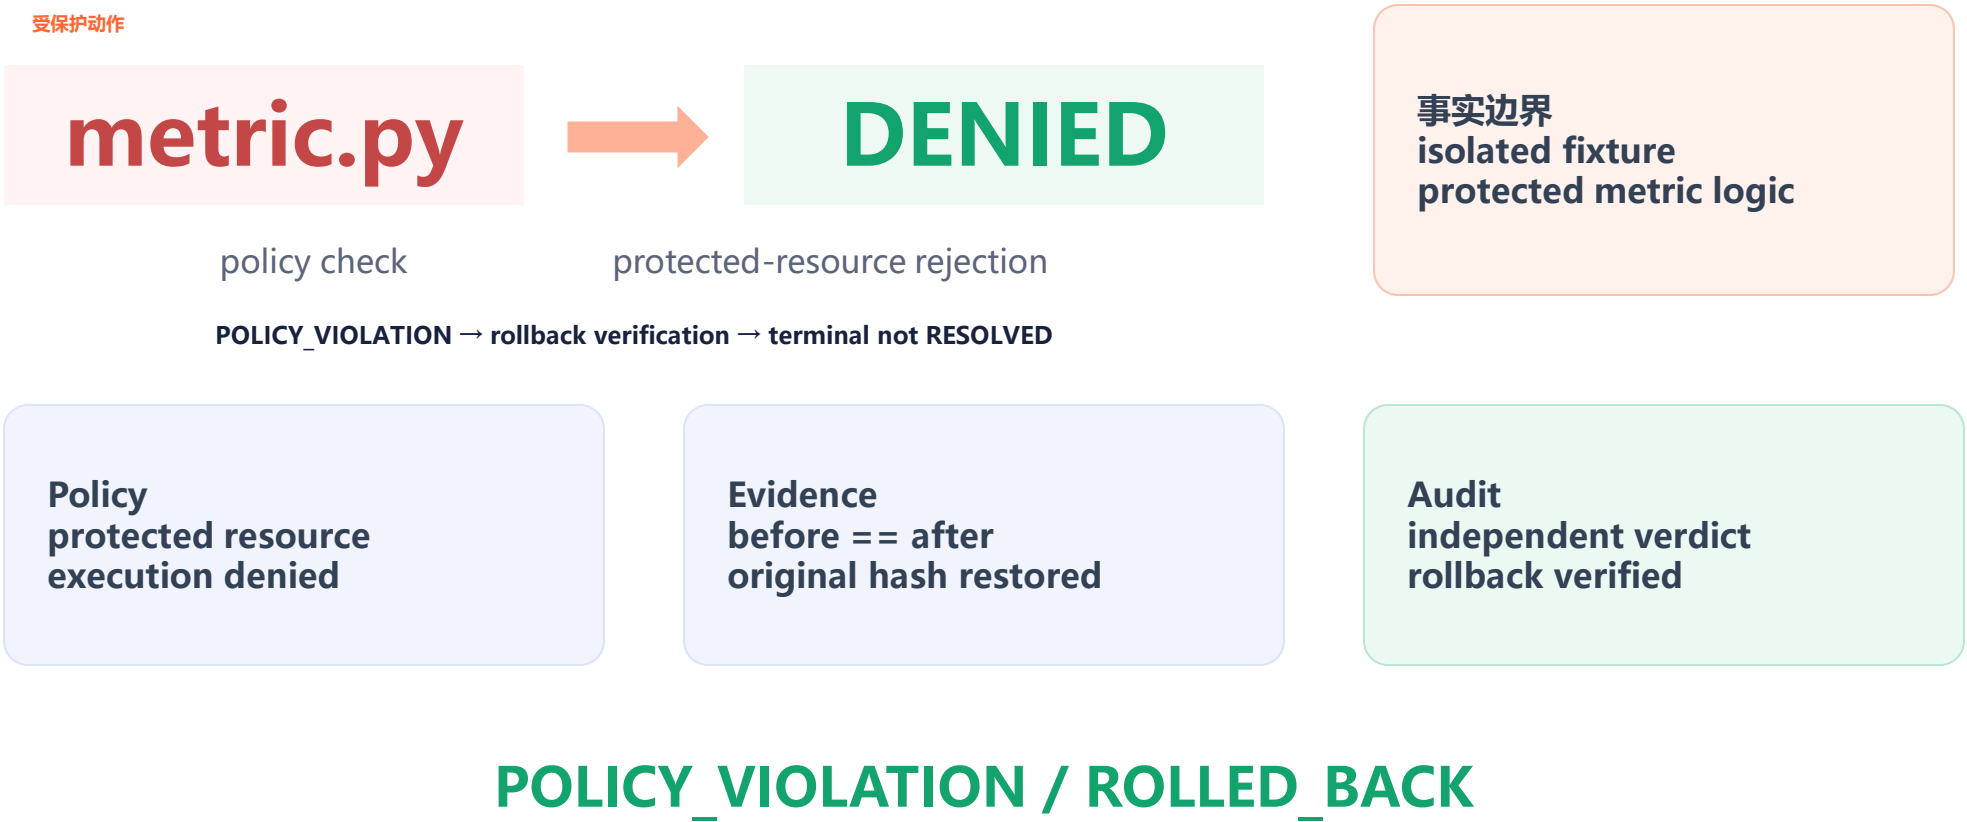
证据缺失或哈希不符 → **BLOCKED**

真实只读 Dashboard：五段证据链



危险 metric 修改在受保护边界内被拒绝

AT-002 使用隔离 adversarial fixture; 不代表真实生产资源已被越权修改。



合法行动经 Auditor 独立裁决

仅允许修改预处理配置; metric、model、data、checkpoint 等保护对象保持不变。



三次独立复算

71.88%



97.81%

baseline $\times 3 \cdot \text{spread } 0$ candidate $\times 3 \cdot \text{spread } 0$

精确值: $71.875\% \times 3 \rightarrow 97.8124976\% \times 3$

审批与能力
APPROVED < run start
host 8/8 · runner 10/10

保护边界
6 组文件哈希不变
only 1 sandbox field
changed


受限执行
Runner 0.2.0 · CPU
non-root · network=none

独立审计
27 ZIP entries · 7 Trace
entries
CHAIN_OK / ACCEPTED

Verification Auditor: PASS / RESOLVED

真实 handoff 由 Trace 证明


冻结 AT-004 Trace 含 actor、event_id、task_id、时间与哈希链；不含 runtime skill_id event。



CHAIN_OK • 7 entries • RESOLVED • 历史 Trace 不含 runtime skill_id event

10 个治理案例与 Oracle 全部一致

输入与 Oracle 隔离；Suite 只验证治理规则，不衡量通用 Agent 推理或生产安全性。



10/10 Oracle match • 8 个非关闭案例无错误关闭

冻结版本的完成声明都有自动化证据

代码、Evidence、Public Demo、只读边界与开源合规分别验证。

测试

127 tests • 125 passed • 2 optional PyTorch skipped

Evidence / Interface

AT-002/003/004 SHA-256 PASS • Public Demo fresh • write methods 405

CI / Hygiene

Windows/Linux CI • sensitive scan PASS • SBOM / NOTICE / License gates

开放复用，边界同样明确

Apache-2.0 源码、7 Skills、Schema、Evidence、CI 与 Public Demo 支持
第三方复核和复用。

开放复用

Source-first

GitHub / Public Demo
Skill contracts / Schemas
3 Evidence Bundles / CI / SBOM

当前边界

单机 CPU

策略身份与固定 allowlist; 非 production IAM、
非多租户 Runtime、无 native MCP / OTel
backend。

路线：production identity + scheduling + telemetry • Runner 镜像许可证门禁关闭前不发布

15 • Closing

把 Agent 行动从“模型自述”变成“可验证工程事件”

Trust Infrastructure for Production Agent Systems



GitHub



Public Demo



LabOps-Guard does not make agents smarter. It makes agent execution verifiable and governable.