

GOAI 2026 世界人工智能开源大赛

LabOps-Guard

可信 Agent 执行与治理基础设施

Trust Infrastructure for Production Agent Systems

Agent 获得真实执行权限后，谁来证明它值得信任？

● 身份

谁在行动？

Identity

● 权限

它获准做什么？

Policy + Approval

● 执行

真实改了什么？

Secure Runner

● 证据

结果能否复核？

Trace + Bundle

● 审计

谁能判定成功？

Independent Auditor

● 边界

失败能否阻断？

BLOCKED / ROLLED_BACK

一次评测漂移，为什么会变成跨角色返工

证据分散、责任交叉、重复运行；LabOps 把采证、审批、执行与审计固化为证据链。

传统实验室

多轮人工返工

值班发现 → 工程师找证据 → 研究员分析 → 负责人审批 → 修改重跑 → 独立复核。

LabOps 引入后

一次受控闭环

Incident → Evidence → RCA → Plan → Approval → Runner → Audit; 每步有 owner 与证据引用。

受控指标：人工接触 • 消息往返 • 重复运行 • 证据完整度 • 错误关闭 • 处理时间

把 Agent 行动变成可验证工程事件

Agent Application → Trust Layer → Secure Runtime → Engineering Environment



Control Plane 保持逻辑架构；Dashboard 只读，不生成综合评分。

任务分派、上下文、状态与责任全部可核验

handoff 绑定 task / incident / attempt、输入输出 artifact、状态、时间与 Matrix event ID。



Commander → Collector → Analyst → Planner → Executor → Auditor

异常恢复
BLOCKED → Retry / Reassign
→ Takeover / new attempt

责任边界
真人 Approval ≠ Human Takeover
Auditor 独占终态裁决

7 个 Skill: 工程契约完整, 证据边界清晰

7 个 Skill 声明 Owner、I/O、调用条件、工具权限、失败、安全、验证与复用。




Registry • Version • Owner • I/O • Invocation • Tool • Failure • Security • Release • Rollback • Quality Eval

Runtime evidence
control-lab-action: Gateway-verifiable • other 6: hook required

一个 Skill 的真实 Tool 绑定

新 live verifier 仅在归档契约与 Gateway / Runner 证据一致时确认。




safe-executor → control-lab-action → labops.runner.execute

Fail closed
missing / reduced / forged contract
→ BLOCKED

Evidence boundary
1 Skill: Gateway-verifiable
6 Skills: CONFIGURED / hook required

真人批准必须与具体计划强绑定

ApprovalGrant v1 绑定计划哈希、范围、副作用、保护对象、预算、时效、nonce 与 run。



任一绑定不一致或重放 → Runner 不启动

Executor 的成功声明不能关闭事故

Auditor 从原始产物独立重算后置条件、保护哈希、审批时序与 Trace。

职责分离

Executor



Auditor

produces artifacts

decides terminal state

只有 verification-auditor 可以产生终态裁决

检查
metric / manifest
approval timing

裁决
PASS / BLOCKED
POLICY_VIOLATION

输入
plan / raw outputs
protected hashes

禁止
编辑产物
复用 claimed score

**Independent Auditor → RESOLVED / ROLLED_BACK /
BLOCKED**

Trace 与 Evidence Bundle 形成可复核链

Matrix 记录事件顺序，Runner 与 MinIO 保存原始产物；Bundle 由 allowlist 封装。




证据缺失或哈希不符 → **BLOCKED**

真实只读 Dashboard：五段证据链



危险 metric 修改在受保护边界内被拒绝

AT-002 使用隔离 adversarial fixture; 不代表真实生产资源已被越权修改。



合法行动经 Auditor 独立裁决

仅允许修改预处理配置; metric、model、data、checkpoint 等保护对象保持不变。



三次独立复算

71.88%



97.81%

baseline $\times 3 \cdot \text{spread } 0$ candidate $\times 3 \cdot \text{spread } 0$

精确值: $71.875\% \times 3 \rightarrow 97.8124976\% \times 3$

审批与能力
APPROVED < run start
host 8/8 · runner 10/10

保护边界
6 组文件哈希不变
only 1 sandbox field
changed


受限执行
Runner 0.2.0 · CPU
non-root · network=none

独立审计
27 ZIP entries · 7 Trace
entries
CHAIN_OK / ACCEPTED

Verification Auditor: PASS / RESOLVED

真实 handoff 由 Trace 证明


冻结 AT-004 Trace 含 actor、event_id、task_id、时间与哈希链；不含 runtime skill_id event。



CHAIN_OK • 7 entries • RESOLVED • 历史 Trace 不含 runtime skill_id event

10 个治理案例与 Oracle 全部一致

输入与 Oracle 隔离；Suite 只验证治理规则，不衡量通用 Agent 推理或生产安全性。



10/10 Oracle match • 8 个非关闭案例无错误关闭

167 项测试覆盖正常闭环与异常接管

Approval、Session 隔离、Recovery / Takeover 与 Skill binding 均有自动化回归。

测试

167 tests passed • Approval / Live Session / Recovery / Skill binding

Evidence / Interface

AT-002/003/004 SHA-256 PASS • Public Demo fresh • write methods 405

Recovery / Takeover

structured failure signal • retry budget • reassign proof • escalation / takeover • Auditor final

开放复用，生产边界与运维路线同样明确

Apache-2.0 源码、7 Skills、Schema、Evidence、CI 与 Public Demo 支持
第三方复核；生产能力分层规划。

开放复用

Source-first

GitHub / Public Demo
Skill contracts / Schemas
3 Evidence Bundles / CI / SBOM

当前边界

单机 CPU

MCP 等价契约；无 RAG：Shared State + Trace
；本地五信号，不宣称 OTel backend、HA 或多
租户。

工具链：版本/权限/迁移已披露 • MCP/OTel 仅适配器路线 • 官方工具不按数量堆
叠

15 • Closing

把 Agent 行动从“模型自述”变成“可验证工程事件”

Trust Infrastructure for Production Agent Systems



GitHub



Public Demo



LabOps-Guard does not make agents smarter. It makes agent execution verifiable and governable.