

GOAI 2026 世界人工智能开源大赛

LabOps Guard

可信 Agent 执行与治理基座

Trust Infrastructure for Production Agent Systems

Agent 获得执行权后

● 身份

谁在行动？

Identity

● 权限

它获准做什么？

Policy + Approval

● 执行

真实改了什么？

Secure Runner

● 证据

结果能否复核？

Trace + Bundle

● 审计

谁能判定成功？

Independent Auditor

● 边界

失败能否阻断？

BLOCKED / ROLLED_BACK

把 Agent 行动变成可验证工程事件

LabOps Guard 约束 AI 工程执行，不承诺通用 Agent OS。

当前目标

可信执行

身份、审批、Runner 与证据
由 Auditor 独立裁决

明确边界

单机 CPU

不含多租户调度、GPU、生产身份、MCP Server
或 RAG。

适用：模型研发 • 评测平台 • AI Infra • 算法治理

五段证据链约束每一次 Agent 工程行动

Control Plane 保持逻辑架构；Dashboard 只读，不拆新服务。



Auditor 独占终态；每个域显示证据来源与限制，不生成综合评分。

每个角色只拥有完成本职工作所需的权限

六个 Identity 共享状态与证据，但 Safe Executor 不能自证成功。




Commander → Collector → Analyst → Planner → Executor → Auditor

人工审批不计作 Agent
审批事件单独留痕
批准必须早于执行

只有 Auditor 可裁决
RESOLVED / ROLLED_BACK / BLOCKED

Identity 与 Skill Registry 统一校验

Registry 提供发现与校验，不接管现有 Skill 执行。



skill_id • version • owner_agents • tool_dependencies • failure_states

未授权 Agent 或 Registry 损坏时 fail closed; 不新增 Agent/Skill。

审批必须先于执行

只有结构化产物可迁移状态；自然语言和 Dashboard 回放不是执行证据。



Trust State Machine v1

拒绝 / 缺审批 / 晚审批
→ BLOCKED

Auditor 裁决
→ RESOLVED / ROLLED_BACK /
BLOCKED

计划与执行职责隔离

Executor 提交结构化 Tool Contract; Gateway 校验后启动一次性断网 CPU 容器。

职责隔离

Safe Executor



Runner

plan + approval → Gateway allowlist → ephemeral container

tool_id • caller_agent_id • skill_id • run_id • idempotency_key

Gateway
固定 task / incident /
image
command + path allowlist

只读输入
project / run 只读
output 与 tmp 可写

运行边界
CPU • non-root
network=none

审计输出
metrics / stdout / stderr
manifest / run_result

无凭据 • 无在线安装 • 不修改原始工作区

Executor 的成功声明不能关闭事故

Auditor 从原始产物独立重算后置条件、保护哈希、审批时序与 Trace。

职责分离

Executor



Auditor

produces artifacts

decides terminal state

只有 verification-auditor 可以产生终态裁决

检查
metric / manifest
approval timing

裁决
PASS / BLOCKED
POLICY_VIOLATION

输入
plan / raw outputs
protected hashes

禁止
编辑产物
复用 claimed score

**Independent Auditor → RESOLVED / ROLLED_BACK /
BLOCKED**

Trace 与 Evidence Bundle 形成可复核链

Matrix 记录事件顺序，Runner 与 MinIO 保存原始产物；Bundle 由 allowlist 封装。



证据缺失或哈希不符 → **BLOCKED**

五段证据链，只读展示

● Identity

6 roles

身份与权限边界

● Policy

Approval timing

禁止动作不可降级

● Execution

Sandbox Runner

CPU · non-root · network=none

● Evidence

Trace + Bundle

状态、检查与证据引用

● Audit

Auditor verdict

独立终态裁决

● Safety

Read-only

无执行 · 无修改 · 无审批

指标回退后，先固定事实

固定 checkpoint、验证集、metric、模型和协议，三次结果均为 71.875%。



三次稳定回退

71.875%



10 条事实

baseline ×3 · spread 0 evidence items with hashes

候选假设前先排除随机波动与受保护资产变化

固定对象
checkpoint / data / metric
model / protocol

唯一近期变化
preprocessing profile
train_augmented

证据边界
6 组保护哈希
before == after

RCA 输入
10 evidence items
with SHA-256

Evidence first → RCA ranks preprocessing drift

单变量沙箱修复通过独立验证

固定对象、人工审批、断网 Runner 与独立复算共同构成完成证明。



三次独立复算

71.88%



97.81%

baseline ×3 · spread 0 candidate ×3 · spread 0

精确值: 71.875% × 3 → 97.8124976% × 3

审批与能力
APPROVED < run start
host 8/8 · runner 10/10

保护边界
6 组文件哈希不变
only 1 sandbox field
changed

受限执行
Runner 0.2.0 · CPU
non-root · network=none

独立审计
27 ZIP entries · 7 Trace
entries
CHAIN_OK / ACCEPTED

Verification Auditor: PASS / RESOLVED

metric.py 越权修改被拒绝


策略与哈希检查识别受保护评测逻辑变化；结果不被接受。



POLICY_VIOLATION / ROLLED_BACK

10 个治理案例检验四项信任控制

输入与 Oracle 分离；执行侧不读取期望终态。该 Suite 不衡量通用 Agent 推理。



治理规则 PASS • 不生成综合 Trust Score

源码可提交，Runner 镜像继续受许可证门禁

Apache-2.0、CI、SBOM、NOTICE 与证据校验分层公开。



已完成

Source / 7 Skills / Schema / 3 Evidence Bundles / CI / Public Demo

入口

jakiic.github.io/LabOps-Guard/ github.com/JAKIIC/LabOps-Guard

发布门禁

基础镜像条款 / Debian 源码义务 / NOTICE / final digest
未关闭前：不发镜像、不建 Tag / Release

当前是可信单机 Runtime，生产化边界清晰

优先守住已验证闭环，不堆叠与复赛无关的平台能力。

当前能力

单机 CPU

策略身份、固定 allowlist、断网 Runner、
Evidence-centric Observability

生产路线

身份 + 调度

OIDC / mTLS、队列、持久幂等、多租户与集中观测需独立实现。

不声称：MCP Server • OTel 后端 • RAG • GPU 调度 • 通用 Agent OS

让 Agent 的工程行动有资格被系统承认

Trust Contract v1 · Trust State Machine v1 · v1.0-rc1



GitHub: github.com/JAKIIC/LabOps-Guard
Demo: jakiic.github.io/LabOps-Guard/